



Llama, OpenAI, Mistral ou Github Copilot

Pourquoi et comment utiliser l'IA pour son application ?



Sommaire

- 01** Introduction aux LLM
- 02** LLM et API développeurs
- 03** Assistance au code
- 04** Quand ne pas utiliser l'IA ?

Partie 1 : Introduction aux LLM

IA et LLM ?



Types d'IA ?

- Symbolique : logique conceptuelle (ex. systèmes experts)
- Apprentissage machine « Machine Learning » **ML**
- « Deep Learning » : apprentissage automatique de représentation **DL**

LLM ?


- Mélange entre les trois types, notamment symbolique et deep learning
- Capables de générer du texte cohérent à la suite d'une invite
- La qualité d'un LLM dépend de la qualité et quantité des données d'entraînement

Usages ?

- Classification, analyse de sentiment, résumé
- Traduction de contenu
- Réponse à des questions diverses (code inclus)


Vers les LLM

systèmes experts




Vers les LLM

Machine Learning



Vers les LLM

Deep Learning



IA et LLM en tant que développeur ?



Critères lors du développement d'applications impliquant l'IA

- L'application doit-elle générer des résumés ?
- L'application doit-elle résoudre des problèmes mathématiques ? (ex. emploi du temps)
- L'application peut-elle passer par un autre biais pour fonctionner ?

Fiabilité de l'IA ?

- La même invite sur le même modèle peut donner plusieurs réponses différentes.
- Certains modèles ne suivent pas correctement les directives.


Contrôler les résultats

- Les LLM et les outils associés acceptent souvent des paramètres impactant la réponse.
- Une génération aléatoire impacte le démarrage de la réponse. Déterminer la **graine** stabilise le résultat.
- La **température** permet de modifier l'attachement au sujet central.

IA et LLM en tant que développeur ?

Contrôle des résultats échantillonnés

- La prochaine réponse du chat est choisie parmi une distribution de probabilité en sortie du modèle
- La température (ratio) **aiguise ou aplatit** la distribution => **favorise ou non** les réponses de haute probabilité
- La valeur **top P** représente le seuil de probabilités hautes cumulées pour sélectionner les réponses.
- La valeur **top K** représente le nb de réponses de plus haute probabilité sélectionnées.



IA et LLM en tant que développeur ?



ChatGPT

Partager

Peux-tu organiser le planning avec les infos suivantes ?

Voici les salles disponibles :

- 1 salle à Paris
- 2 salles à Nantes
- 1 salle à Marseille

Voici les formateurs disponibles :

- Pierre à Marseille dispense PHP, Symfony et Laravel
- Paul à Paris dispense C++, C# et Unity
- Jacques à Nantes dispense Python, Photoshop et Blender

Les formations durent 5 jours, de lundi à vendredi.

Les formateurs peuvent se déplacer vers les autres villes, mais si un participant proche d'une ville souhaite participer en présence, on préférera lui allouer une salle. Si les contraintes sont compliquées, on peut déplacer une formation à une autre semaine.

- Aude, à Marseille veut suivre PHP en présentiel
- Boris, à Marseille, veut suivre Symfony en présentiel
- Claude, à Paris, veut suivre Symfony, en présentiel ou à distance
- Diane, à Nantes, veut suivre Unity en présentiel
- Émile, à Nantes, veut suivre C# à distance ou en présentiel
- François, à Paris, veut suivre C# à distance
- Guillaume, à Nantes, veut suivre Photoshop, à distance ou présentiel

Voici un planning optimisé en tenant compte des contraintes et préférences :

Semaine 1



Paris (1 salle disponible)

Poser une question



Rechercher



Raisonner



ChatGPT peut faire des erreurs. Envisagez de vérifier les informations importantes.



Résolution de contraintes avec ChatGPT

Partie 2 : LLM et API développeurs

Palmarès 2025-03 GML



Rank★ (UB)	Rank (StyleCtrl)	Model	Arena Score	95% CI	Votes	Organization	License
1	3	Grok-3-Preview-02-24	1404	+5/-6	9871	xAI	Proprietary
1	1	GPT-4.5-Preview	1398	+5/-6	9871	OpenAI	Proprietary
3	6	Gemini-2.0-Flash-Thinking-Exp-01-21	1382	+5/-4	22004	Google	Proprietary
3	3	Gemini-2.0-Pro-Exp-02-05	1379	+4/-4	19963	Google	Proprietary
3	2	ChatGPT-4o-latest (2025-01-29)	1374	+4/-5	21831	OpenAI	Proprietary
6	4	DeepSeek-R1	1360	+7/-7	12224	DeepSeek	MIT
6	11	Gemini-2.0-Flash-001	1355	+6/-6	17689	Google	Proprietary
6	3	o1-2024-12-17	1351	+4/-3	24350	OpenAI	Proprietary
8	11	Gemma-3-27B-it	1341	+8/-6	6248	Google	Gemma
9	11	Qwen2.5-Max	1340	+5/-4	16493	Alibaba	Proprietary
9	7	o1-preview	1335	+4/-4	33186	OpenAI	Proprietary
12	11	o3-mini-high	1325	+4/-5	13615	OpenAI	Proprietary
12	12	DeepSeek-V3	1318	+4/-5	22848	DeepSeek	DeepSeek
12	14	Command A (03-2025)	1312	+9/-10	3000	Cohere	CC-BY-NC-4.0
13	20	GLM-4-Plus-0111	1310	+7/-8	6039	Zhipu	Proprietary
13	20	QwQ-32B	1310	+8/-13	3403	Alibaba	Apache 2.0
13	17	Qwen-Plus-0125	1310	+7/-7	6061	Alibaba	Proprietary

GPT 4.5 et Grok3 (propriétaires) dominant sur la précision et le raisonnement général parmi les modèles de langage généralement disponibles.


Pour actualiser : <https://lmarena.ai/?leaderboard>

API : Mistral AI



Plateforme Française proposant via API ou interface, des modèles d'excellente qualité perçue.
Le modèle de base des exemples de code est satisfaisant.

API : Mistral



Une plateforme classique mais complète, proposant des agents ou des API d'embedding.

API : Mistral



Vue d'usage sur chaque modèle, en jetons ou en devises (€).

API : Mistral (développeur)



```
1 import os
2 from dotenv import load_dotenv
3 from mistralai import Mistral
4
5 load_dotenv()
6
7
8 API_KEY: str = os.environ["MISTRAL_API_KEY"]
9 MODEL: str = "mistral-large-latest"
10
11
12 client = Mistral(api_key=API_KEY, timeout_ms=60_000)
13
14 chat_response = client.chat.complete(
15     model=MODEL,
16     messages=[
17         {
18             "role": "user",
19             "content": "...",
20         },
21     ],
22 )
```

Run main_categorize

```
/home/steve/Code/python/mistral-simple-chat/.venv/bin/python /home/steve/Code/python/mistral-simple-chat/main_categorize.py
Sad
Happy
Process finished with exit code 0
```

Mistral propose des bibliothèques pour consommer ses API.
Le temps de réponse sans streaming est assez rapide si le nombre de jetons à générer est bas.

API : Llama




Grand modèle de langage open-source publié par Meta
Rythme de parution avec un retard sur l'état de l'art proposé par Meta.
Attention : Meta Llama n'est pas disponible en Europe (ciblé par l'UE)

API : Llama via Ollama




Ollama est un programme fournissant un moteur d'exécution utilisant des modèles, compatibles avec Llama de Meta.
Ce programme peut être accompagné d'outils (ex. OpenWebUI) pour en faire un serveur web REST, compatible avec les API de chez OpenAPI.

Ollama et OpenWebUI




OpenWebUI est un site web interfacé avec Ollama, qui offre une interface utilisateur similaire à celles proposées par Mistral, ChatGPT et consorts.
L'application facilite la gestion de modèles hébergés sur ollama.com

Ollama et OpenWebUI



Exemple de discussion avec un modèle Llama 3.2 à 1 milliard de valeurs.
Le modèle Llama 3.3 n'existe à l'heure actuelle qu'en 70 milliards de valeurs
(nécessite au moins 96Go de RAM ou 80Go de mémoire vidéo)

Ollama et API



Exemple de discussion avec un modèle Llama 3.2 à 1 milliard de valeurs.
Le modèle Llama 3.3 n'existe à l'heure actuelle qu'en 70 milliards de valeurs
(nécessite au moins 96Go de RAM ou 80Go de mémoire vidéo)

Ollama et API (Développeur)



```
1 """
2 Example code for llama-simple-chat.
3
4 This script makes call to the Ollama API hosted on the local machine.
5 Uses the specific 'ollama' python package to make the calls.
6 """
7 from collections.abc import Iterator
8
9 import ollama
10
11 HOST: str = "localhost:7869"
12 MODEL: str = "llama3.2:1b"
13 MODEL: str = "deepseek-r1:14b"
14
15
16 def main(): 1 usage
17     """Main function."""
18     client: ollama.Client = ollama.Client(HOST) # Create an API client
19     response: Iterator = client.chat(model=MODEL, messages=[{"role": "user", "content": "For you who code in Python"}])
20
21 Run main_async
```

```
/home/steve/Code/python/llama-simple-chat/.venv/bin/python /home/steve/Code/python/llama-simple-chat/main_async.py
<think>
I'm sorry, but I can't access real-time data or the internet. However, I can help guide you on how to write Python code for various tasks. If you have
For example:
- Data analysis
- Web scraping
- Machine learning
- Networking
- Anything else
Just let me know what you're working on!
```

Exemple de discussion avec un modèle Deepseek R1 à 14 milliards de valeurs.
Le modèle Llama 3.3 n'existe à l'heure actuelle qu'en 70 milliards de valeurs
(nécessite au moins 96Go de RAM ou 80Go de mémoire vidéo)

Le modèle RAG



RAG : quid ?

- « Retrieval Augmented Generation » ou Génération augmentée par la Récupération
- Technique Mixte mêlant IA Récupérative et Générative
- La part récupérative consiste à compléter la base d'informations du LLM avec des documents privés
- Pour que la part générative analyse et traite ces nouvelles informations

Outils de la RAG

- Un **modèle d'« Embeddement »** ou d'embarquement permettant de transformer une information
- (documents textes / images / sons / graphes) en un **Vecteur** de nombres de dimension importante
- Ces nombres représentent une un « *mieux disant ou barycentre* » des notions similaires préexistantes
- Une **base donnée Vectorielle** stockent ces vecteurs comme un Espace métrique muni d'une distance
- Ces outils des algorithmes proches à la démarche « *K nth neighbours* »

Partie 3 : Assistance au code



Extension de développement pour IDE :

- Visual Studio Code
- JetBrains (*IntelliJ, PHPStorm, PyCharm etc.*)

Comparable à d'autres outils tels que TabNine

Windsurf



Efficacité de windsurf

- Caractères par opportunité : 1,27
- Pourcentage de code écrit : 44,6%

Caractères par opportunité ?

Ratio de tentatives de suggestion par entrée ×
Ratio de tentatives de suggestion non avortées ×
Ratio de suggestions confirmées ×
Moyenne de jetons par suggestion confirmée ×
Nombre moyen de caractères par jeton

Versus


Copilot

- A un ratio de suggestions confirmées de 30%
- **Propose moins de suggestions (latence élevée)**

TabNine

- Bon ratio de confirmation
- **Mais via des suggestions très courtes**

Windsurf



windsurf propose un chat pour obtenir des informations sur le code.
Malheureusement, un seul modèle est disponible dans la version gratuite.

Windsurf



Forces de windsurf

- Rapidité des suggestions même en version gratuite
- Pertinence de nombreuses suggestions selon le contexte
- Le mode chat accepte un contexte (sélection ou fichier) pour orienter la réponse

Mode «agent»

- Codeium peut générer du code directement dans vos scripts via des prompts
- Il est également possible d'apporter des modifications à du code existant

Cursor IDE



Environnement de développement intégré orienté autour de l'IA

Cursor IDE



Principales fonctionnalités de Cursor :

- Mode agent avec création et modification de fichiers
- Mode conversation classique avec connaissance du contexte du projet
- Mode d'autocomplétion live avec contexte

Avantages de Cursor (vs Codeium) :

- Opportunités couvrant plus de cas
- Pas de mode agent dans Codeium
- Mode agent avec utilisation du contexte existant
- Acceptation/refus des modifications d'agent à tout moment

Cursor IDE

Mode Chat



Principales fonctionnalités du mode Chat :

- Discussion avec possibilités de questionner le code
- Propose des bouts de code sans les appliquer au projet
- Utilise le contexte du projet pour répondre

Attention :

- Le choix du modèle importe en mode Chat
- Certains modèles sont meilleurs en langage, notamment le français


Cursor IDE Modèles




Le modèle Sonnet 3.7 est actuellement le plus réputé en code + instructions
(Source : *vellum.ai*)

Fastest and Most Affordable Models


Fastest Models ⓘ



Lowest Latency (TTFT) ⓘ



Cheapest Models ⓘ



Le modèle Llama 70b est actuellement le plus rapide
(Source : *vellum.ai*)

Cursor IDE

Modèles et code




HumanEval: Coding Leaderboard

Comparison of pre-trained proprietary and open-source models for code generation.

Model	HumanEval (0 shot)
Claude 3.5 Sonnet	93.7%
GPT-4o	90.2%
AWS Nova Pro	89%
Llama 3.1 405b	89%
Grok-2	88.4%
Claude 3.5 Haiku	88.1%
Qwen2.5-70b	88%
GPT-4o mini	87.2%
GPT-Turbo	87.1%
GPT-4	86.6%
Grok-2 mini	85.7%
AWS Nova Lite	85.4%
Claude 3 Opus	84.9%
OpenAI o1-mini	82.6%
AWS Nova Micro	81.1%
Llama 3.3 70b	80.5%


Meilleur taux de satisfaction atteint par Sonnet 3.5 (3.7 n'est pas évalué)
(Source : *vellum.ai*)

Cursor IDE Modèles



Sélection de modèles disponibles pour Cursor (d'autres peuvent être ajoutés)

Cursor IDE Modèles



Attention, les modèles n'acceptent pas un contexte illimité.
Cela va impacter le travail sur de grands projets.

Github Copilot



GitHub
Copilot

Copilot et chiffres

Github Copilot



- **Assistant de programmation** « *Pair Programmer-Assistant* »
- Utilisant par défaut le modèle de langage **GPT-4** *par défaut*

Usages principaux

- **FOURNIT** des suggestions de code, *à la volée*
- **EXPLIQUE** les concepts, les changements d'une « *pull/merge request* »
- **GENERE** des squelettes, des modèles de fichiers, des *tests* et autres *pipelines CI/CD*
- **CORRIGE** des erreurs et autres entorses au plan qualité
- **EVALUE** dans le cadre d'une revue de code

Github Copilot VS autres LLMS



Intérêts circonstanciels

1) Copilot est directement **intégré aux gabarits graphiques des IDE** comme VS Code/ neovim /...

- En dehors de l'agent conversationnel classique « **Chat** »
- **Menu contextuel** - click droit sur une sélection
- **Terminaux** pour piloter les commandes systèmes
- **Autocomplétion** à la volée pour les suggestions « *Snippets* »

Plus généralement, le travail de l'IA opère sur le **contexte** du code Applicatif

- **Refactoring** et autres éditions sont effectués dans le cadre d'un **ESPACE DE TRAVAIL** « *Workspace* »
- Variables / fonctions / classes / méthodes
- Variables d'environnements

Github Copilot



Terminal : *Ctrl + i*

A screenshot of a Windows PowerShell terminal window. The title bar shows 'PROBLÈMES', 'SORTIE', 'TERMINAL', and 'PowerShell Extension'. The command prompt shows the path 'C:\Users\matthieu\Desktop\dawan\dawan_work\sandbox\my-fastapi-app>'. A GitHub Copilot suggestion is displayed, showing a purple icon, a description in French, and a PowerShell command. A tooltip for the command icon indicates 'Insérer dans le terminal (Ctrl+Alt+Enter)'. At the bottom, there is a 'Demandez à Copilot' bar with a microphone icon, 'GPT-4o', and a send button. Below this are buttons for 'Exécuter', 'Insérer', 'Fermer', and a refresh icon.

PROBLÈMES SORTIE TERMINAL ... PowerShell Extension

PS C:\Users\matthieu\Desktop\dawan\dawan_work\sandbox\my-fastapi-app>

trouver toutes les description des interfaces réseaux connectées au routeur

`Get-NetAdapter | Where-Object {$_.Status -eq "Up"} | Format-Tal`

Insérer dans le terminal (Ctrl+Alt+Enter)

Demandez à Copilot @ GPT-4o

Exécuter Insérer Fermer ↺

Github Copilot

Chat



CONVERSATION



Copilot is powered by AI, so mistakes are possible.
Review output carefully before use.

 ou tapez # pour attacher le contexte

 pour converser avec des extensions

Tapez / pour utiliser des commandes

 Ajouter le contexte...

créer une application python 3.13 avec FastAPI et un
fichier requirements.txt sans versions et sans le
modèle microsoft



Demander 

GPT-4o  

Github Copilot

Workspace : */new*



CONVERSATION



application Python 3.13 avec FastAPI :

▼ my-fastapi-app

> app

≡ requirements.txt

ⓘ README.md

Créer un espace de travail...

▼

Quels modules ajouter au requirements.txt ?

 Ajouter le contexte...


Demander à Copilot

@ 

Demander ▼ GPT-4o ▼  ▼

Github Copilot

Edits : *Ctrl + Shift + i*



Github Copilot

suggestions




```
main.py [●] [●] [▶] [v] [□] [..]
p > [🔗] main.py > ...
1  from fastapi import FastAPI, APIRouter
2
3  app = FastAPI()
4
5  # Créer un routeur
6  router = APIRouter()
7
8  @router.get("/items")
9  def read_items():
10     return {"items": ["item1", "item2", "item3"]}
11
12  # Inclure le routeur dans l'application principale
13  app.include_router(router)
14
15  @app.get("/")
16  def read_root():
17     return {"Hello": "World"}
18
19  # Add additional routes here
```

Conserver Annuler [🔗] | 2 sur 2 [↑] [↓] [👤]

Github Copilot

Mode agent



Github Copilot



Bonnes pratiques

Les prompts doivent être cadrés

- Les éléments arbitraires *librairies / versions* doivent être spécifiés correctement
- OU délégués à des outils « *experts* »
- Les bonnes pratiques de génie logicielle / performances doivent être comprises et spécifiées
- Les connaissances initiales des librairies / framework sont nécessaires.
- (Re)itérer une suggestion en précisant le contenu pour « *élaguer le scope* » de propositions
- Ne pas hésiter d'écrire une procédure en « *pseudo-code* »
- Maîtriser la *grammaire* française / anglaise

BUT : Reproduire voire Automatiser des procédures taillées par le tandem Développeur / Assistant IA

Indicateurs de performance

Selon une analyse publiée par Accenture - Microsoft de mai 2024

- **Méthodologie** : en essai contrôlé randomisé
- **Echantillon**: 2 groupes ~ 450 développeurs – Avec Github Copilot Pro (GPT4) / Sans
- **Durée** : 6 mois

Activité
(Avec)

35%

suggestions acceptées
en développement

88%

des 35%
retenues à la revue

Productivité
(Avec/Sans)

+50%

pull requests

+15%

taux de fusion

Efficiency
(Avec/Sans)

+50%

de builds
ante déploiement

+45%

taux de succès
post déploiement

satisfaction
(Avec)

96%

sur le Jour 1

90%

augmentation
du bien-être

Partie 4 : Quand ne pas utiliser l'IA ?

Le débutant (expérience basse)



- N'a pas souffert assez d'obstacles pour mieux comprendre les écosystèmes qu'il utilise
- Va générer du code sans le comprendre (ou le lire) et l'utiliser avec les risques que cela implique
 - Ne va pas retenir ou retenir avec plus de difficulté

Le débutant et le vibe coding



Vibe Coding ?

- Concept décrit par Andrej Karpathy (OpenAI) en février 2025
- Un développeur utilise uniquement une IA pour générer du code et redirige la génération
- L'idée est qu'un béotien pourrait réaliser des projets logiciels sans rien savoir
- Fonctionne sur des usages modestes

Un utilisateur fonctionnant essentiellement via cet outil n'est pas un développeur. Cela obligera dans un temps court les entreprises qui ne le faisaient pas à proposer des tests de développement en temps réel.

- Le «vibe coding» représente un risque :
 - Risque de sécurité : le code peut laisser des vulnérabilités béantes que l'utilisateur n'est pas en mesure d'évaluer
 - Risque de bugs : pour la même incompetence de l'utilisateur, l'IA peut introduire des bugs qu'un développeur confirmé aurait pu repérer. Ceci est cumulatif.
 - Maintenabilité : la génération est souvent dépourvue de documentation ou de commentaires, et souvent de structure.

L'outil qui remplaça le cerveau



Vous pensez que l'IA n'est qu'une aubaine ?

Quelques exemples

- «Rédigez un mail de relance»
- «Code suggéré par un stagiaire» (appel API)
- «Échec catastrophique» : <https://nmn.gl/blog/vibe-coding-fantasy>

Un utilisateur fonctionnant essentiellement via cet outil n'est pas un développeur.
Cela obligera dans un temps court les entreprises qui ne le faisaient pas
à proposer des tests de développement en temps réel pour discriminer.

- Le «vibe coding» représente un risque :
 - Risque de sécurité : le code peut laisser des vulnérabilités béantes que l'utilisateur n'est pas en mesure d'évaluer, par manque de culture notamment.
 - Risque de bugs : pour la même incompétence de l'utilisateur, l'IA peut introduire des bugs qu'un développeur confirmé aurait pu repérer. Ceci est cumulatif.
 - Maintenabilité : la génération est souvent dépourvue de documentation ou de commentaires, et souvent de structure.

L'enjeu comme mesure



Le vibe coding n'est pas un problème dans le cas suivants :

- Vous souhaitez réaliser un script dans le cadre d'un outil personnel limité
- Vous devez réaliser une maquette de projet dont **aucune ligne** n'ira en production
- Si vous savez ce que vous faites, vous pouvez glaner quelques idées.

L'important est que l'enjeu du code que vous souhaitez générer reste faible.

Ou que vous ayez les connaissances, le discernement et les habitudes pour poser les bonnes questions.

En conclusion



**Merci pour votre
attention**

Avez-vous des questions ?

